

Instituto Federal de Pernambuco - Campus Paulista

Docente: Rodrigo Lira

Discentes: Karen Ribeiro, Rodrigo Sena

Disciplina: Tópicos Especiais em Inteligência Artificial

Repositório: [Github](#)

## Relatório dos resultados obtidos da atividade de Algoritmo Genético

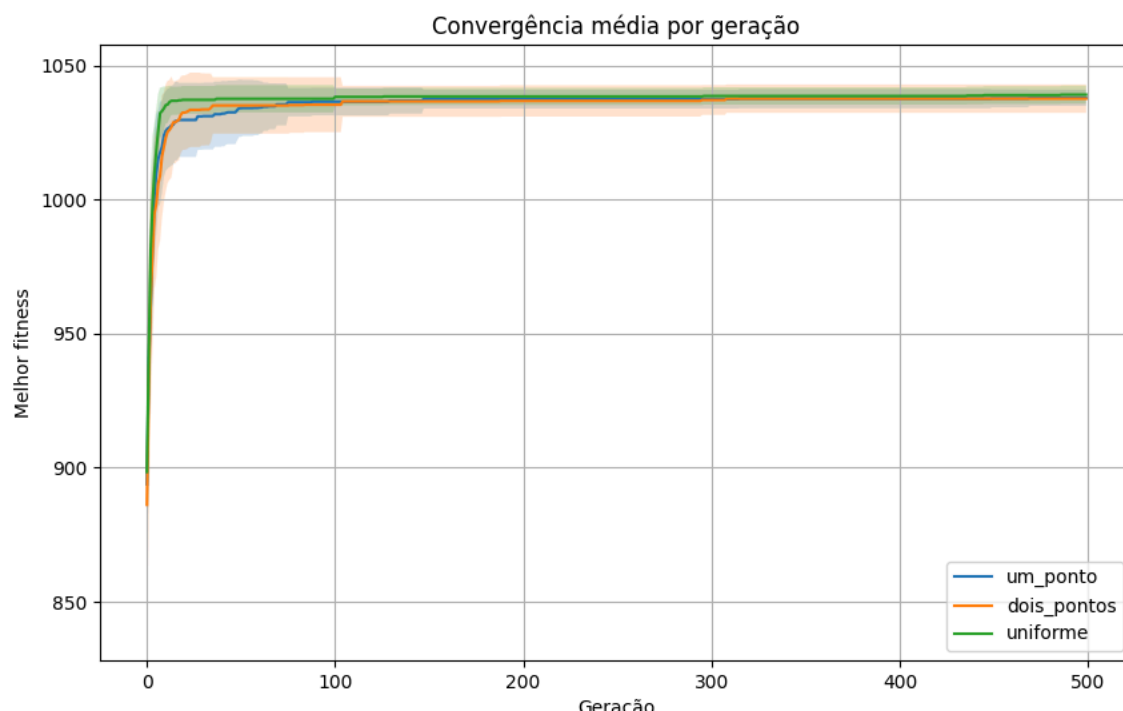
### Atividade 4 - Implementação de AG para Knapsack

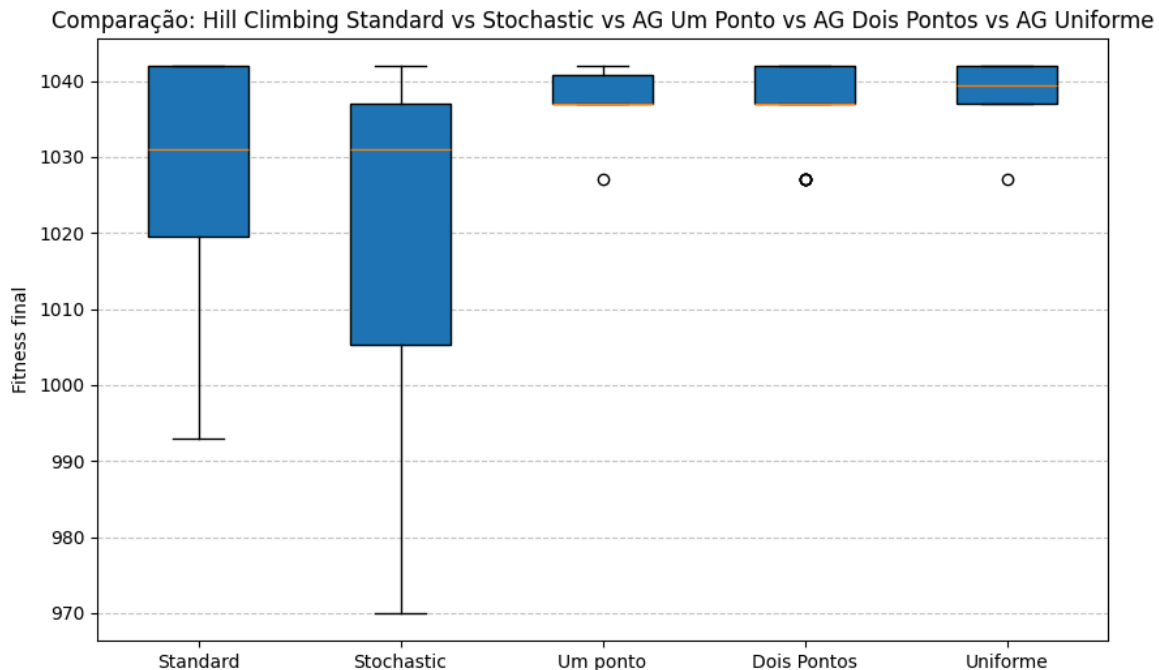
Após a criação do Algoritmo Genético(AG) para a resolução do problema 0/1 do Knapsack com 20 dimensões, executamos o algoritmo 30 vezes, em seguida, fizemos para cada configuração do AG:

- Cálculo da média
- Desvio padrão do fitness

```
=== Estatísticas Finais ===
                        Média  Desvio Padrão
Configuração
um_ponto      1038.000000    3.051286
dois_pontos    1037.666667    5.371273
uniforme       1039.166667    3.394553
```

Em seguida, foi gerado um gráfico de convergência das configurações do AG, onde podemos observar o melhor fitness por iteração, e boxplot:





**Comentário:** Os três tipos de crossover apresentaram desempenhos médios semelhantes, com valores de fitness final próximos de 1038 e baixa variabilidade entre as execuções. O crossover uniforme destacou-se ligeiramente, atingindo a maior média de fitness (aprox 1039,2) e mantendo um desvio padrão reduzido (aprox 3,39), o que indica maior estabilidade e consistência dos resultados. Já o crossover de dois pontos apresentou a maior dispersão (desvio padrão aprox 5,37), sugerindo maior sensibilidade à variação aleatória na população. Pelo gráfico de convergência mostra uma similaridade no desempenho das três configurações do algoritmo genético, onde as curvas convergem para um valor de fitness máximo de aproximadamente 1042. Além disso, é possível observar que em todos os tipos de crossover do AG são atingidas boas soluções de forma rápida, com estabilização das curvas em torno da 100ª geração, mantendo o valor até a última iteração com quedas quase que imperceptíveis, senão inexistentes, demonstrando que o algoritmo encontrou um ótimo lugar. Sendo assim, concluímos que existe convergência precoce e eficiência na busca evolutiva para esse caso. Para gerar o boxplot, fez-se necessário a reutilização de valores prévios obtidos em outras atividades (resultados finais do algoritmo de hill climbing padrão e hill climbing estocástico). Quando comparados aos algoritmos Hill Climbing (Standard e Stochastic), vemos que os AGs apresentam maior robustez e menor variabilidade nos resultados. O Algoritmo Hill Climbing padrão demonstra produzir valores de fitness médio, porém com algumas execuções de baixo desempenho, demonstrando uma menor consistência nos seus resultados. Já o Algoritmo estocástico, mostra uma dispersão ainda maior, indicando que a sua aleatoriedade aumenta a exploração, fazendo com que ele passe a explorar mais, ficando menos em lugares ótimos, mas acaba tornando o método menos previsível. O Hill Climbing, e aqui pontuamos a versão estocástica principalmente, exibiu maior dispersão e menor previsibilidade, enquanto os AGs mantiveram faixas pequenas de variação e médias maiores de fitness final. Sendo assim, em termos de estabilidade e consistência de desempenho, os AGs se saíram melhor.